### Методы повышения производительности .NETприложения на примере программы поиска дубликатов

Юрий Малич

### О себе

- Программирую примерно с 1996 года, с MS DOS, i386
- На C# .NET с первых версий
- Закончил ПГУПС по специальности Автоматика и телемеханика на ж/д транспорте
- Писал статьи по архитектуре микропроцессоров для сайтов iXBT.com, fcenter.ru, 3dnews.ru
- Microsoft Certified Professional, Microsoft Specialist: Programming in C#

# О программе Duplicate Files Search & Link

#### Задача

- Расхламление, наведение порядка и освобождение рабочего пространства за счёт удаления лишних файлов
- Ускорение работы системы (больше пространства, меньше фрагментация)
- Поиск дубликатов файлов и жёстких ссылок с максимально возможной скоростью даже на старых компьютерах

# О программе Duplicate Files Search & Link

#### Какие проблемы приходится решать?

- Больше файлов => больше времени нужно на чтение и сравнение
- Антивирусы замедляют доступ к файлам
- Чем больше файлов, тем больше памяти требуется программе

# О программе Duplicate Files Search & Link

- Поиск дубликатов файлов в выбранных папках
- Поиск жёстких ссылок, символьных ссылок на файлы (NTFS, ReFS, EXT2,3,4)
- Поиск дубликатов медиафайлов (.mp3, .mp4, .jpg etc) по медиаконтенту с игнорированием метаданных (тэгов и т.п.)
- Замена дубликатов файлов на жёсткие или символьные ссылки
- Удаление дубликатов (в корзину или насовсем)
- Собирается сразу под 4 платформы: .NET4.7.2, .NET 6.0, 7.0, 8.0 (32+64 бит)

#### Алгоритмы поиска дубликатов

- Побайтное сравнение файлов одинакового размера между собой
- Посчитать хэш каждого файла по отдельности и сгруппировать по хэшам

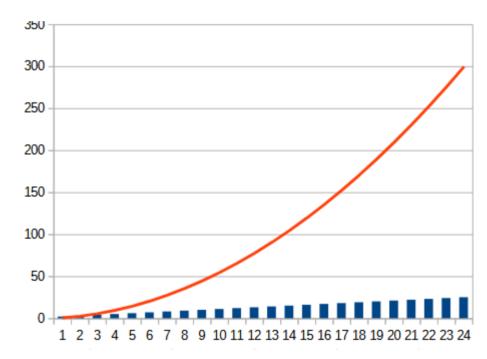
#### Побайтное сравнение файлов между собой

### **ОТЕСТВОЙНЕТВА:**

- Не нужно читать файлы целиком, если они не равны в начале
- Высокая скорость сравнения небольших групп
- Низкая ресурсоёмкость и нагрузка на процессор
- Надёжность

#### Побайтное сравнение файлов между собой

- Недостатки:
- Квадратичная алгоритмическая сложность в самом худшем сценарии O((n^2-n)/2)



#### Хэширование файлов и сравнение хэшей

- **ф** Достоинства:
- Алгоритмическая простота алгоритма сравнения O(n)
- Алгоритмы криптографического хэширования из коробки

#### Хэширование файлов и сравнение хэшей

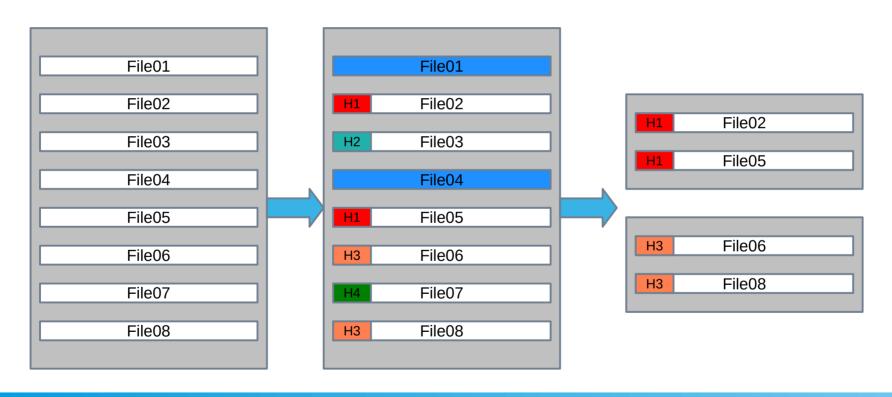
### 🛑 Недостатки:

- Каждый файл нужно прочитать целиком
- Ресурсоёмкость, высокая нагрузка на процессор
- Скорость хэширования одного файла намного ниже скорости сравнения двух файлов
- Вероятность коллизий (одинаковые хэши разных данных) больше нуля

# **Гибридное решение: скомбинировать достоинства, нивелировать недостатки.**

- В небольших группах файлы сравниваются побайтно
- Для больших групп используется хэширование, совмещённое со сравнением
- Результаты хэширования используются для последующей группировки сравнения по подгруппам

### Гибридное сравнение



#### 1. Простейшее побайтное сравнение буферов

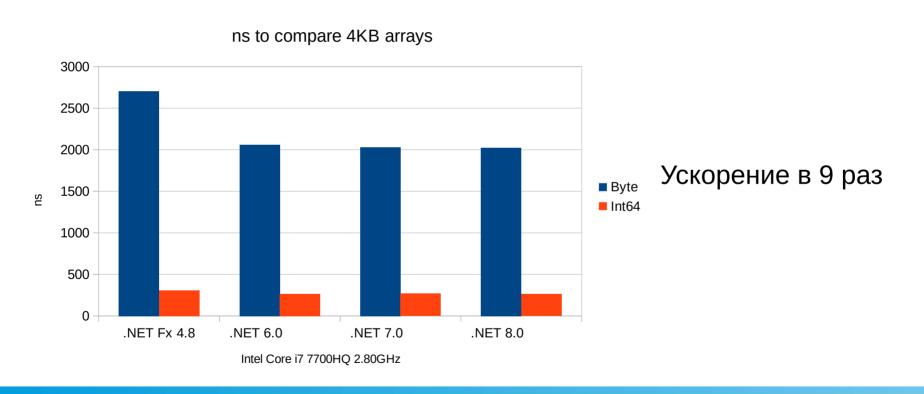
```
for (int i = 0; i < buf1.Length && i < buf2.Length; i++)
{
    if (buf1[i] != buf2[i])
    {
        return false;
    }
}</pre>
```

Слишком медленно, неэффективно

#### 2. Сравнение Int64-словами через fixed-pointer в unsafe-коде

```
fixed (byte* pBuf1 = buf1, pBuf2 = buf2)
    int i8 = 0, i = 0;
    int size8 = size / sizeof(long);
    var p1 = (long*)pBuf1;
    var p2 = (long*)pBuf2;
    for (; i8 < size8; i8++)</pre>
        if (p1[i8] != p2[i8])
            return i8 * sizeof(long);
    i += i8 * sizeof(long);
    for (; i < size; i++)</pre>
        if (pBuf1[i] != pBuf2[i]) { return i; }
```

#### Сравнение 4К-массивов побайтно и словами Int64 в BenchmarkDotNet



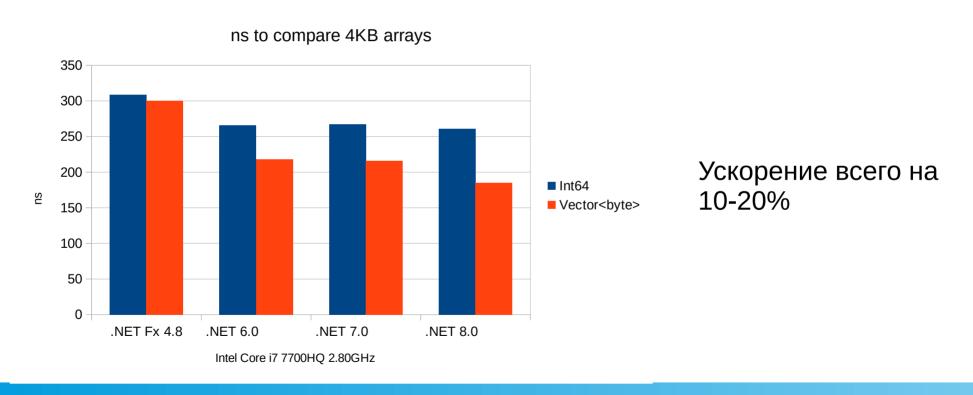
#### 3. AVX-сравнение через 32-байтный Vector<br/>byte>

```
var countVectors = size / Vector<byte>.Count;
var sizeAligned = countVectors * Vector<byte>.Count;

for (int i = 0; i < sizeAligned; i += Vector<byte>.Count)
{
    var vector2 = new Vector<byte>(buf2, i);
    var vector1 = new Vector<byte>(buf1, i);

    if (vector1 != vector2)
    {
        return i;
    }
}
```

#### Сравнение 4K-массивов словами Int64 и 256-битными векторами в BenchmarkDotNet



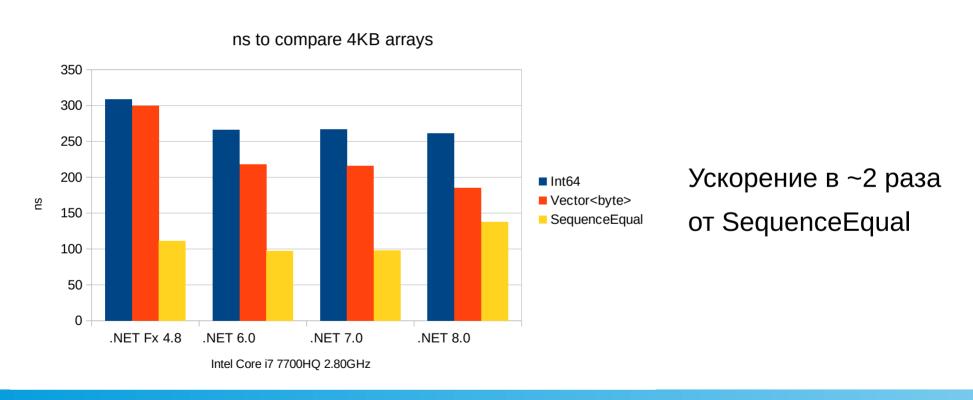
#### 3. AVX-сравнение через 32-байтный Vector<br/>byte>, дизассемблерный код

```
M01 L00:
                 eax, r10d
       cmp
                 near ptr M01 L09
       jae
       lea
                 esi,[rax+1F]
                 esi,r10d
       cmp
       jae
                 near ptr M01 L09
       vmovupd
                 ymm0,[rdx+rax+10]
                 eax, r9d
       cmp
                 near ptr M01 L09
       jae
                 esi,r9d
       cmp
      yae
vmovupd v
                 near ptr M01 L09
                 ymm1,[rcx+rax+10]
       vpcmpeqb ymm0,ymm1,ymm0
       vpmovmskb esi,ymm0
                 esi,0FFFFFFF
       cmp
       jne
                 near ptr M01 L06
       add
                 eax,20
                 eax,r11d
       cmp
       jl
                 short M01 L00
```

# 4. AVX-сравнение через MemoryExtensions.SequenceEqual (Nuget System.Memory)

```
var span1 = buf1.AsSpan();
var span2 = buf2.AsSpan();
return span1.SequenceEqual(span2);
```

#### Сравнение 4К-массивов тремя разными функциями BenchmarkDotNet



#### AVX Vector<br/> byte> vs SequenceEqual в дизассемблере (.NET 7.0)

SequenceEqual		CompareBuffersVectorized	
M01_L01: vmovdqu	ymm0,ymmword ptr [rcx+rax]	M01_L00: cmp jae cmp jae vmovupd cmp jae cmp jae cmp jae vmovupd	eax,r10d near ptr M01_L09 esi,[rax+1F] esi,r10d near ptr M01_L09 ymm0,[rdx+rax+10] eax,r9d near ptr M01_L09 esi,r9d near ptr M01_L09 ymm1,[rcx+rax+10]
vpcmpeqb vpmovmskb cmp jne add cmp ja	ymm0,ymm0,[rdx+rax] r9d,ymm0 r9d,0FFFFFFFF short M01_L06 rax,20 r8,rax short M01_L01	vpcmpeqb vpmovmskb cmp jne add cmp jl	

#### Хэширование файлов

$$h = hash(data)$$

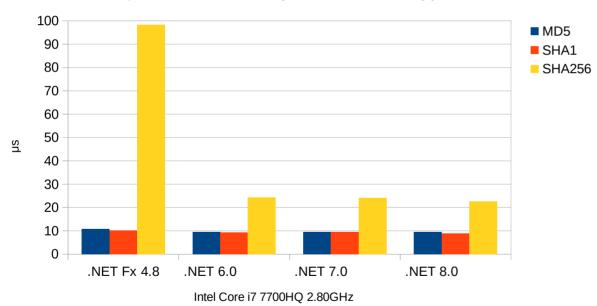


```
SHA1("Hello") => f7ff9e8b7bb2e09b70935a5d785e0cc5d9d0abf0
```

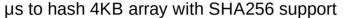
SHA1("Hello.") => 9b56d519ccd9e1e5b2a725e186184cdc68de0731

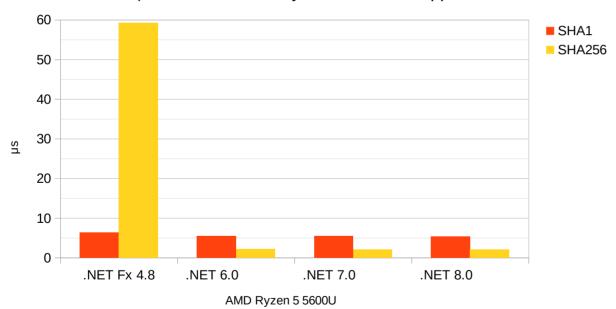
# Сравнение SHA1 и SHA256 в BenchmarkDotNet на процессоре без поддержки Intel SHA extensions





# Сравнение SHA1 и SHA256 в BenchmarkDotNet на процессоре с поддержкой Intel SHA extensions





	SHA1	SHA256	Ratio
.NET Fx 4.8	6,4 µs	59,3 µs	923%
.NET 6.0	5,5 µs	2,1 µs	39%
.NET 7.0	5,4 µs	2,1 µs	39%
.NET 8.0	5,4 µs	2,1 µs	39%

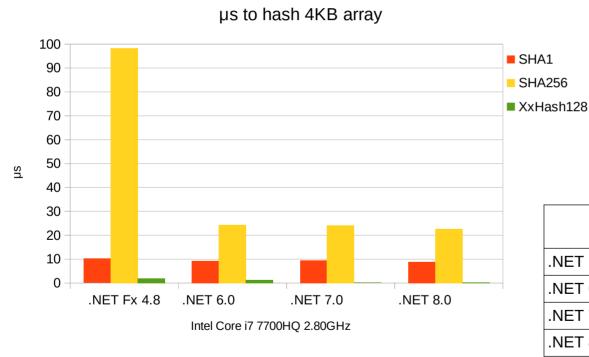
### Некриптографический хэш-алгоритм XxHash128

Реализован в пакете System.IO.Hashing 8.0

#### Достоинства:

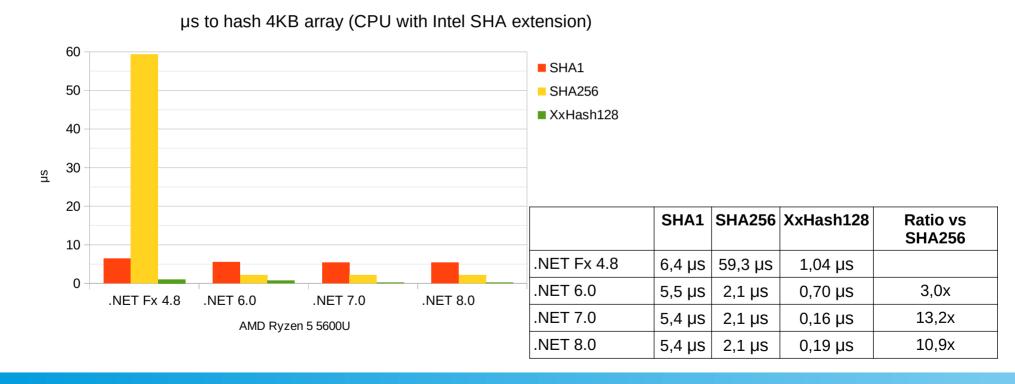
- Скорость, оптимизирован для SSE2/AVX
- Длина 128 бит = 16 байт
- Низкий рейтинг коллизий https://github.com/Cyan4973/xxHash/wiki/Collision-ratio-comparison

#### Сравнение SHA1 и SHA256, XxHash128 в BenchmarkDotNet



	SHA1	SHA256	XxHash128	Ratio vs SHA1
.NET Fx 4.8	10,2 µs	98,2 µs	1,90 µs	5,4x
.NET 6.0	9,3 µs	24,4 µs	1,30 µs	7,2x
.NET 7.0	9,4 µs	24,1 µs	0,20 µs	46,3x
.NET 8.0	8,8 µs	22,6 µs	0,27 µs	32,9x

#### Сравнение SHA1 и SHA256, XxHash128 в BenchmarkDotNet



### Сравнение хэш-значений размером 32 байта между собой

1. Сравнение 64-битными словам через fixed-pointer \*ulong

```
fixed (byte* pBuf1 = buf1, pBuf2 = buf2)
{
    var pLong1 = (ulong*)pBuf1;
    var pLong2 = (ulong*)pBuf2;

    return pLong1[3] == pLong2[3]
         && pLong1[2] == pLong2[2]
         && pLong1[1] == pLong2[1]
         && pLong1[0] == pLong2[0];
}
```

### Сравнение хэш-значений размером 32 байта между собой

2. Сравнение 64-битными словам через Span<ulong>

06	ратный порядок	Г	<b>Трямой порядок</b>	
shr	ecx,3	shr	ecx,3	
shr	r10d,3	shr	r10d,3	
стр	ecx,3	test	ecx,ecx	[0]([3])
jbe	short M01_L05	je	short M01_L05	
mov	rax,[r8+18h]	mov	rax,[r8]	
стр	r10d,3	test	r10d,r10d	[0]([3])
jbe	short M01_L05	je	short M01_L05	
стр	rax,[r9+18h]	стр	rax,[r9]	
jne	short M01_L02	jne	short M01_L02	
		стр	ecx,1	[1]
		jbe	short M01_L05	
mov	rax,[r8+10h]	mov	rax,[r8+8]	
		стр	r10d,1	[1]
		jbe	short M01_L05	
стр	rax,[r9+10h	стр	rax,[r9+8]	
jne	short M01_L02	jne	short M01_L02	

Обратный порядок		Прямой порядок		
		стр	ecx,2	[2]
		jbe	short M01_L05	
mov	rax,[r8+8]	mov	rax,[r8+10h]	
		стр	r10d,2	[2]
		jbe	short M01_L05	
стр	rax,[r9+8]	стр	rax,[r9+10h]	
jne	short M01_L02	jne	short M01_L02	
		стр	ecx,3	[3]
		jbe	short M01_L05	
mov	rax,[r8]	mov	rax,[r8+18h]	
		стр	r10d,3	[3]
		jbe	short M01_L05	
стр	rax,[r9]	стр	rax,[r9+18h]	
sete	al	sete	al	
movzx	eax,al	movzx	eax,al	

### Сравнение хэш-значений размером 32 байта между собой

3. AVX- и SSE2-сравнение через Vector<br/>byte>

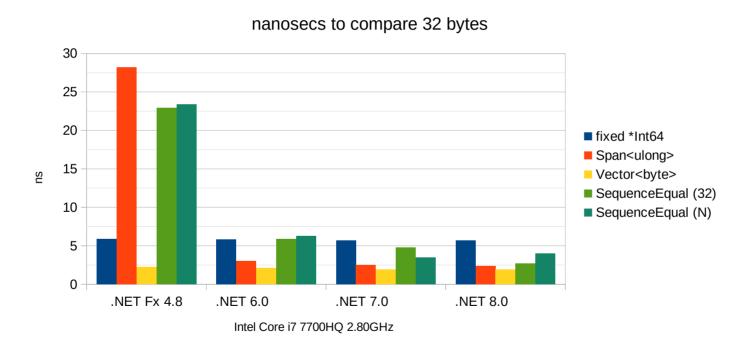
```
if (Vector<byte>.Count == 32)
    var vector2 = new Vector<byte>(buf2, 0);
    var vector1 = new Vector<byte>(buf1, 0);
    return vector1 == vector2;
if (Vector<byte>.Count == 16)
    var vector12 = new Vector<byte>(buf1, 16);
    var vector22 = new Vector<byte>(buf2, 16);
    return vector12 == vector22
            && new Vector<byte>(buf1, 0) == new Vector<byte>(buf2, 0);
```

### Сравнение хэш-значений размером 32 байта между собой

4. SequenceEqual (const 32) var span1 = buf1.AsSpan(0, 32);var span2 = buf2.AsSpan(0, 32);return span1.SequenceEqual(span2); 5. SequenceEqual (N) var buf1Span = buf1.AsSpan(0, size); var buf2Span = buf2.AsSpan(0, size); var res = buf1Span.SequenceEqual(buf2Span); return res;

### Сравнение хэш-значений размером 32 байта между собой

Сравнение всех реализаций по скорости в BenchmarkDotNet



### Файловые операции и многопоточность

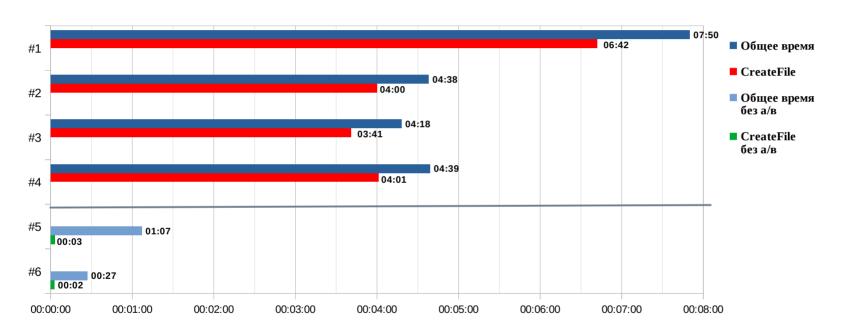
#### Какая самая «дорогая»/медленная системная функция в программе?

CreateFile(..)!

- Чтение с диска файловых атрибутов метаданных из таблиц
- Проверка прав доступа пользователя
- Самая ресурсоёмкая операция: проверка антивирусом(!)

# Файловые операции и многопоточность

#### Сравнение 63 000 файлов в 1 поток с антивирусом и без



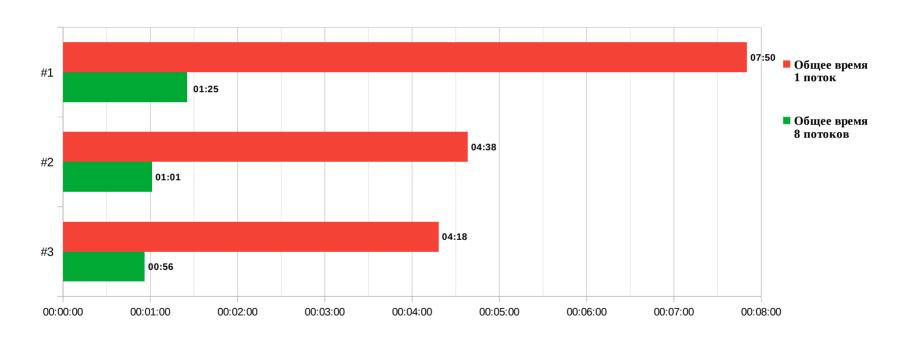
4 минуты = в среднем ~4 мс на 1 файл

### Файловые операции и многопоточность

#### Оптимизации

- 1. Сокращение количества открытий файлов
- 2. Совмещение сравнения с хэшированием
- 3. Закрытие файловых стримов происходит в фоновом потоке
- 4. Многопоточность для SSD и/или независимых HDD

### Прирост от многопоточности при поиске дубликатов на SSD



### Задачи при синхронизации доступа потоков к дискам

- Определить, какие физические диски в системе являются SSD, какие HDD, а какие прочими носителями (через WinAPI, WMI)
- Определить разделы носителей и назначенные им буквы (через WMI)
- Обеспечить синхронизацию одновременного доступа с учётом типа носителя

Кто знает, для чего эти металлические стержни?



Это жезлы (tokens) системы блокировки ж/д перегона



### Распараллеливание сравнения файлов Классы управления доступом

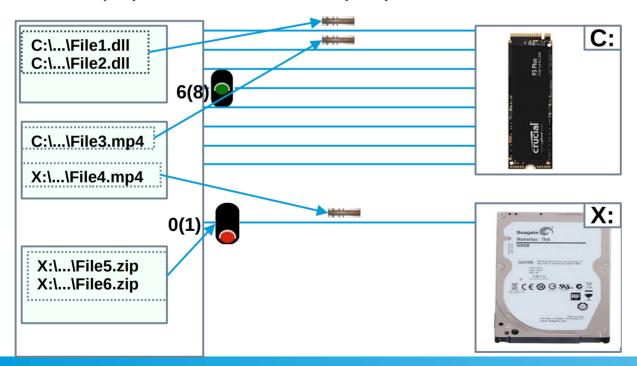
- DriveAccessManager (управляет семафорами для носителей, раздаёт токены)
- DriveAccessSemaphore (регулирует доступ к носителю)
- SingleEnterToken (токен одиночной блокировки для одного файла)
- DoubleEnterToken (токен двойной блокировки для файлов на разных носителях)

### Распараллеливание сравнения файлов

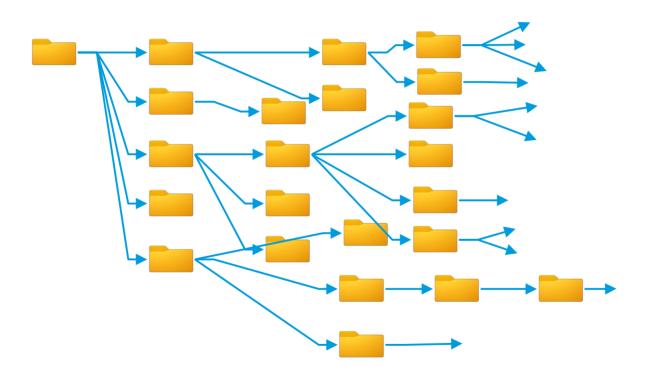
- Файлы группируются по размеру
- Группы файлов одинакового размера сравниваются параллельно через Parallel.ForEach()
- Ограничение доступа к дискам регулируется через семафоры, выдаваемые DriveAccessManager
- На каждое сравнение файлов выдаётся токен, освобождается после сравнения

### Распараллеливание при сравнении файлов

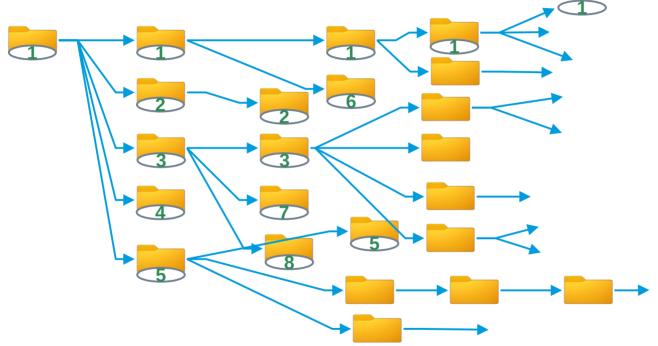
О семафорах и токенах в программе.



### Параллельное сканирование каталогов

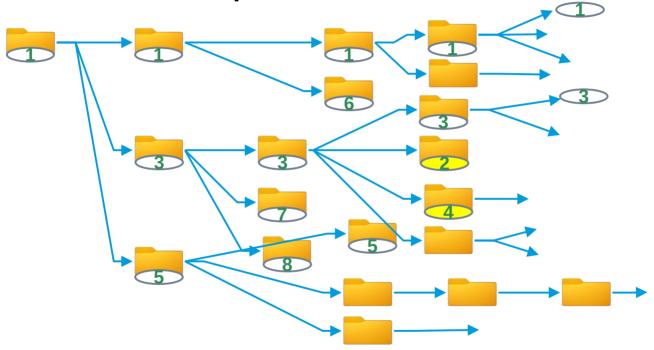


Параллельное сканирование каталогов



Parallel.ForEach + MaxDegreeOfParallelism + Interlocked-счётчик

Параллельное сканирование каталогов



Parallel.ForEach + MaxDegreeOfParallelism + Interlocked-счётчик

### Что общего в этих строках?

"c:\Program Files\Microsoft Visual Studio\2022\Community\Common7\IDE\ProjectTemplates"

"c:\Program Files\Microsoft Visual Studio\2022\Community\Common7\IDE\PublicAssemblies"

"c:\Program Files\Microsoft Visual Studio\2022\Community\Common7\IDE\ReferenceAssemblies"

"c:\Program Files\Microsoft Visual Studio\2022\Community\Common7\IDE\ProjectTemplates"

"c:\Program Files\Microsoft Visual Studio\2022\Community\Common7\IDE\PublicAssemblies"

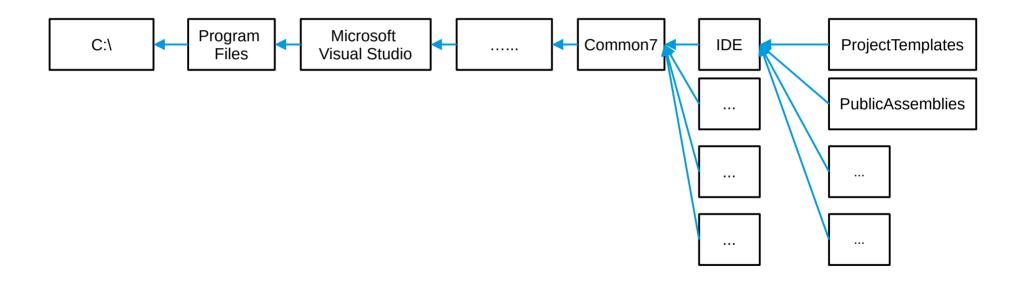
"c:\Program Files\Microsoft Visual Studio\2022\Community\Common7\IDE\ReferenceAssemblies"

#### Решение — класс AbsolutePath

```
internal class AbsolutePath : IEquatable<AbsolutePath>, IComparable<AbsolutePath>
    public AbsolutePath? Parent { get; }
    public string Name { get; }
    public int Length => GetLength();
    public int Levels => GetLevels();
    public AbsolutePath(string name, AbsolutePath? parent)
        Parent = parent;
        Name = GetSharedName(name ?? string.Empty);
    }
```

#### Класс AbsolutePath

Связный список узлов для одного пути



- Некоторые недостатки AbsolutePath против строк
  - Нужно выделять временную строку для WinApi-функций
  - Динамическое вычисление длины строк

### **Преимущества AbsolutePath против строк**

- Строгая типизация
- Использует значительно меньше памяти в целом
- Ссылки на имя, родительский и корневой каталоги без выделения памяти
- Одинаковые имена каталогов и файлов не дублируются
- Пути между собой сравниваются намного быстрее, чем строки



### Преимущества AbsolutePath против строк

Сравнение на равенство двух таких путей

"c:\Program Files\Microsoft Visual Studio\2022\Community\Common7\Packages\00098"

"c:\Program Files\Microsoft Visual Studio\2022\Community\Common7\Packages\00099"

в BenchmarkDotNet на .NET 7.0

- string.Equals(OrdinalIgnoreCase): 48 нс
- AbsolutePath.EqualsIgnoreCase: **2 нс**

### **Преимущества AbsolutePath против строк**

• AbsolutePathDriveRoot - быстрое получение информации о корневой папке и томе по пути.

```
internal sealed class AbsolutePathDriveRoot : AbsolutePath
{
   public override string FileSystemName { get; }

   public override Win32.FileSystemFlags FileSystemFlags { get; }

   public override DriveType DriveType { get; }

   public override string VolumeName { get; }

   public override bool IsOnSsd { get; set; }

   public override uint SectorSize { get; }
```

### **Преимущества AbsolutePath против строк**

AbsolutePathSymlinkPoint - встроенная поддержка символьных ссылок

### ArrayPool<T>

Вместо библиотечного свойства **ArrayPool<br/>byte>.Shared** программа использует разделяемый экземпляр, созданный **ArrayPool<br/>byte>.Create()** 

### Преимущества

- Меньше суммарный объём памяти, выделенной на массивы
- Позволяет освободить ссылку на выделенную память после использования
- В моих сценариях скорость одинакова на .NET 7.0, но реализация через Create() быстрее на .NET Fx 4.8

#### ListPool<T>

Хранит List<T> и, подобно ArrayPool<T>, используется для уменьшения трафика памяти

```
internal sealed class ListPool<T>
    public static int MaxCount { get; set; } = Math.Max(32, Environment.ProcessorCount * 2);
    public static ListPool<T> Shared { get; } = new ();
    private ConcurrentBag<List<T>> _listContainer = new ();
    private int _countInContainer = 0;
    [ThreadStatic] private static Box<List<T>>? _box;
    private static Box<List<T>> BoxedList { ...}
    public List<T> Rent() { ... }
    public void Return(ref List<T>? listRef) { ... }
```

```
Rent() - аренда
var box = BoxedList;
var list = box.Item;
if (list is not null)
    box.Item = null;
    return list;
if (_countInContainer > 0 && _listContainer.TryTake(out list))
    Interlocked.Decrement(ref _countInContainer);
    return list;
return new List<T>();
```

```
Return() - возврат
var list = listRef;
listRef = null;
if (list is null || _countInContainer >= MaxCount) { return; }
list.Clear();
var box = BoxedList;
if (box.Item is null)
     box.Item = list;
     return;
if (_countInContainer < MaxCount)</pre>
     _listContainer.Add(list);
     Interlocked.Increment(ref _countInContainer);
```

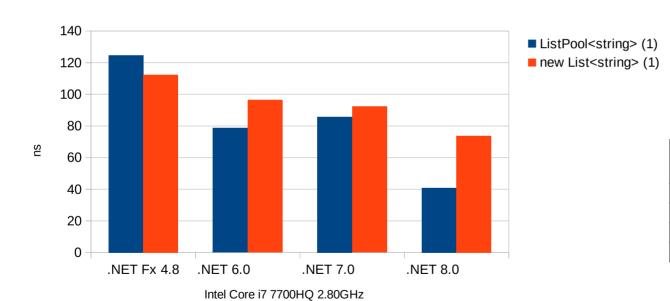
```
Box<List<T>>
public class Box<T>
{
    public T? Item { get; set; }
}
```

```
RentedListWrapper<T>
```

```
internal struct RentedListWrapper<T> : IDisposable
    private List<T>? _rentedList;
    public List<T> List => _rentedList ?? new List<T>();
    public RentedListWrapper(List<T> cachedList)
        _rentedList = cachedList;
    public void Dispose()
        ListPool<T>.Shared.Return(ref _rentedList);
using var wrappedList = ListPool<FileNameSize>.Shared.RentWrapped();
```

### ListPool<T>

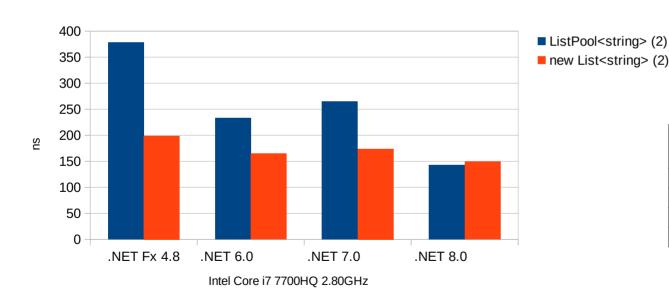
• Сравнение по скорости ListPool<string>.Rent() и new List<string>() для одного списка с добавлением 6-ти объектов в список



	ListPool <t> (1)</t>	Alloc	new List <t> (1)</t>	Alloc
.NET Fx 4.8	124,8 ns	0	112,3 ns	185 B
.NET 6.0	78,7 ns	0	96,4 ns	176 Б
.NET 7.0	85,9 ns	0	92,3 ns	176 Б
.NET 8.0	40,9 ns	0	73,7 ns	176 Б

### ListPool<T>

• Сравнение по скорости ListPool<string>.Rent() и new List<string>() для 2-х списков с добавлением 6-ти объектов в каждый список



	ListPool <t> (2)</t>	Alloc	new List <t> (2)</t>	Alloc	
.NET Fx 4.8	378,3 ns	0	199,1 ns	369 B	
.NET 6.0	233,1 ns	0	164,9 ns	352 Б	
.NET 7.0	264,8 ns	0	173,9 ns	352 Б	
.NET 8.0	142,7 ns	0	149,7 ns	352 Б	

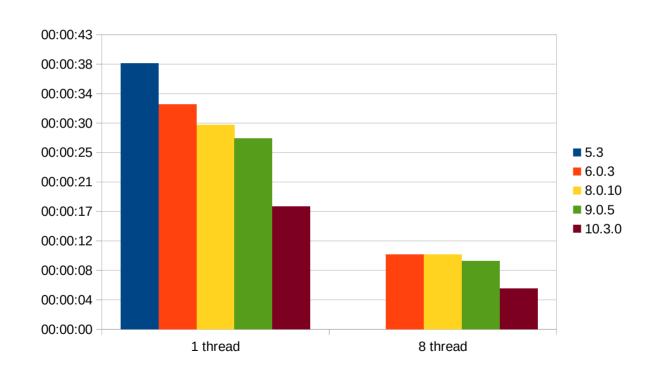
### StringBuilderPool

Хранит StringBuilder, аналогичен ListPool<T>

```
internal sealed class StringBuilderPool
    public static int MaxCount { get; set; } = 32;
    public static StringBuilderPool Shared { get; private set; } = new StringBuilderPool();
    private int _countInContainer;
    private ConcurrentBag<StringBuilder> _stringBuilders = new ();
    [ThreadStatic] private static Box<StringBuilder>? _box;
    private static Box<StringBuilder> BoxedStringBuilder{ ... }
    public StringBuilder Rent() { ... }
    public void Return(StringBuilder? sb){ ... }
```

### Заключение

### Комплексный прирост от всех оптимизаций разных версий



# Заключение

### Отзывы :)

	Всего записей: <b>67</b>   Зарегистр. <b>26-02-2012</b>   <u>Отправлено:</u> <b>13:34 03-04-2023</b>
la_tangram	Редактировать   Профиль   Сообщение   Цитировать   Сообщить модератору
Junior Member	rj12 Версией 10.2.1 просканировал 90 Гиг данных на SSD за 1 минуту, в несколько потоков - это фантастика!)) Ранее, чем мельче файлы проверялись, тем медленнее шёл процесс. Спасибо!
	Всего записей: <b>141</b>   Зарегистр. <b>15-03-2005</b>   <u>Отправлено:</u> <b>07:47 04-04-2023</b>

### Спасибо за внимание!

### Вопросы?

#### Контакты:

email: yurymalich@yandex.ru

② @Yury\_Malich

web: http://www.malich.org/duplicate\_searcher

XING: https://www.xing.com/profile/Yury\_Malich