# Когда в С# не хватает С++ vol 3

Сергей Балтийский JetBrains

# Why?

- Скорость
  - Оптимизация CPU
  - Затраты на переключение контекста
  - Память
    - Управление памятью
    - ∞ GC
- Legacy
  - Библиотеки на C/C++

## How?

- ∞ COM
- Plnvoke
- Native Memory in C#

## Storing C# Data in Native Memory

- Unmanaged Heap
  - Marshal::AllocHGlobal
- A single managed array
- Disk file mapped into memory
- Shared memory
- Memory outside 32-bit process 4GB space
- Not a graph of linked managed objects

## Отличие от обычных структур

- Структура скрыта от GC
  - ∞ Нет memory traffic
  - Нет нагрузки при обходе графа при запуске GC
- Явный/ручной memory management
- ∞ Можно работать над locality

## Lifetime

- Managed объекты работоспособны пока доступны
- Native memory в какой-то момент надо явно освободить
  - Явный момент окончания использования
  - Все клиенты знают об этом
  - В структуре данных есть средства контроля

## Во время загрузки

- Возможность прочитать как один BLOB
  - Bulk file read
  - Memory-mapped file
- ∞ Нет создания managed-объектов при десериализации
- Максимальная ленивость

## Приличное С# АРІ

- Работа как с обычной структурой данных
  - A не набор C-style функций

# Safety

- Ошибки в нативном коде
  - Ошибки в работе с нативной памятью
    - Чтение за пределами данных
    - 🗠 Запись в «чужую» память
- Нарушение времени жизни
  - Работа с кодом или памятью после освобождения

# Реализация

- ~ 1) Native code
  - 2) C#-only

## Native Code Implementation

- CPP/CLI (see vol. 1)
- COM (see vol. 1)
- Plnvoke
  - Выглядит проще
  - Много справочной информации

  - Все конвенции надо продумывать самостоятельно
    - ∞ Calling conventions, threading, memory ownership, lifetimes

## Точка входа в DLL

- DllImportAttribute
  - Поиск DLL только по имени файла
  - Проблема выбора 32/64/OS-specific реализации
- LoadLibrary + GetProcAddress
  - + GetDelegateForFunctionPointer
    - ∞ (или dlopen + dlsym)
    - Загрузка DLL по явному пути
      - ∞ В том числе Side-by-Side
      - Выбор для нужной разрядности и OS

    - UnmanagedFunctionPointerAttribute

### Native Pointers in Plnvoke

```
[StructLayout(LayoutKind.Sequential)]
public struct POINT
{ public int x; public int y; }
[StructLayout(LayoutKind.Sequential)]
public class CPoint
{ public int x; public int y; }
[DllImport("my.dll")]
public static extern int Hit(ref POINT ppt);
[DllImport("my.dll")]
public static extern int Hit(CPoint ppt);
[DllImport("my.dll")]
public static extern int Hit(POINT *ppt);
```

## **C#-only Implementation**

- ➤ Pros:
- Код на одном языке
- Единый codebase, нет дублирования деклараций
- AnyCPU & portable
- ∞ Нет возни с native DLLs
- → Heт переключения managed/native и маршаллинга

## **C#-only Implementation**

- ∞ Cons:
- Очень ограниченные возможности С# при работе с native memory
  - ∞ Нет ООП на blittable types
  - Невозможно использовать генерический код
- Нет возможности писать высокоуровневый код
- ∞ Нет средств контроля работы с native memory из .NET

# Доступ к памяти

Readonly

Read+Write

## Read-Only Data Structures

- Предварительно подготовленные данные
- Нет memory allocator
- Нет опасности испортить память
- Возможные промахи по адресам
  - Moryт вызвать access violation без последствий
    - Убедиться, что они ловятся
  - Могут прочитать бессмысленные данные
    - ∞ Маркеры / magic numbers где уместно

#### **Use Case**

#### Hash table с большим количеством данных

```
return new Dictionary<string, string>()
 { "Á", "\u00C1" },
 { "á", "\u00E1" },
 { "Ă", "\u0102" },
 { "ă", "\u0103" },
 { "∾", "\u223E" },
 { "∿", "\u223F" },
 { "∾̳", "\u223E\u0333" },
 { "Â", "\u00C2" },
 { "â", "\u00E2" },
 { "´", "\u00B4" },
 { "А", "\u0410" },
 { "а", "\u0430" },
 { "Æ", "\u00C6" },
```

# Медленное конструирование

- $\infty$  JIT
- CPU time
- Memory\*

## Альтернативная загрузка

C# array field with initializer

Быстро, но память неструктурированная

```
internal static readonly UInt32[] HashByName = new UInt32[6377]{
0x00000002u, 0x00000021u, 0x000000C73u, 0x00000000u, 0x0000000u, 0x00000000u,
0x000003F1u, 0x4D96D5CCu, 0x000000B5u, 0x6F86802Au, 0x0000029B3u, 0x43609526u,
0x00002197u, 0x538C7B14u, 0x000022FCu, 0x63104C69u, 0x000002923u, 0x00000000u,
0x00002640u, 0x61C808F1u, 0x0000003BDu, 0x97AA0769u, 0x0000022A8u, 0x5336850Du,
0x00002A22u, 0x00000000u, 0x00000000u, 0x00000000u, 0x00000000u, 0x00000000u,
0x00000000u, 0x00000000u, 0x00000000u, 0x0B607F82u, 0x00000229Eu, 0x80C8F570u,
0x00002247u, 0x6D685FB2u, 0x00002312u, 0x09B499B2u, 0x000002AEDu, 0x00000000u,
0x00000000u, 0x53C063E9u, 0x0000045Au, 0x6D003F87u, 0x000002AB9u, 0x00000000u,
0x03382AC6u, 0x1BDA6044u, 0x00000402u, 0x4E489470u, 0x000002ADBu, 0x00000000u,
0x0000230Au, 0x4EE64817u, 0x0000003BCu, 0x00000000u, 0x00000000u, 0x7D787AE8u,
0x00000000u, 0x00000000u, 0x00000000u, 0x7D904194u, 0x000002322u, 0x49ACFEFFu,
0x0000229Bu, 0x00000000u, 0x00000000u, 0x2E7EDF8Du, 0xDD3ED835u, 0x00000000u,
0x00002AA6u, 0x271CBA76u, 0x00002261u, 0x1D42C693u, 0x000000A8u, 0x7CE2111Eu,
```

- Код загрузки в .ctor / .cctor
  - Вызов спец-функции над спрятанным филдом

```
ldc.i4
newarr
field valuetype '$$method0x6002768-2'
call void RuntimeHelpers::InitializeArray(Array, RuntimeFieldHandle)
stsfld unsigned int32[] MyClass::HashByName
```

#### Спрятанный филд

```
.field static assembly valuetype '__StaticArrayInitTypeSize=25508'
'$$method0x6002768-2' at I_00018CD0
```

#### • Спец-функция RuntimeHelpers::InitializeArray

```
[MethodImplAttribute(MethodImplOptions.InternalCall)]
public static extern void InitializeArray(Array array, RuntimeFieldHandle
fldHandle);
```

```
FCIntrinsic("InitializeArray", COMArrayInfo::InitializeArray,
CORINFO_INTRINSIC_InitializeArray)
```

```
FCIMPL2(void, COMArrayInfo::InitializeArray, ArrayBase* pArrayRef, HANDLE
handle)
...
#if BIGENDIAN
...
#else
    memcpyNoGCRefs(dest, src, dwTotalSize);
#endif
```

- Одна GC-аллокация массива
- Копирование данных блоком;
- Данные доступны как массив или fixed byte\*

## Hash Table in Native Memory

- Read-only, все данные известны при построении
- 🕶 Выбираем размер и хороший хеш
- Открытая адресация
- Массив структур
  - ∞ Ключ

  - ∨ Индекс в массиве хеш
    - ∞ по модулю
    - → + probing

## Hashtable Record

#### Ячейка таблицы

```
[StructLayout(LayoutKind.Sequential, Pack = 2)]
private struct Cell
{
   public UInt16 dwHash;
   public UInt16 rvaName;
   public fixed UInt16 wszValue [2];
}
```

```
Header Cell
```

## Hashtable Record

```
public UInt16 dwHash; 
public UInt16 rvaName; 
public fixed UInt16 wszValue[2];
                         0x3D3C7462u, 0x0000298Du
            { "⦍", "\u298D" },
           Unicode Character 'LEFT SQUARE BRACKET WITH TICK IN TOP CORNER' (U+298D)
```

## Извлечение примитивных данных

#### Reinterpret-Cast

```
byte* pbCells;
byte* pbCell = pbCells + nCell * sizeof(Cell);
Cell* pCell = (Cell*)pbCell;

ushort dwHash1 = pCell->dwHash;

Cell cell = *pCell;

ushort dwHash2 = cell.dwHash;
```

## Извлечение примитивных данных

#### Pointer arithmetic

```
Cell* pCells;
Cell* pCell = pCells + nCell;
ushort dwHash1 = pCell->dwHash;
Cell cell = *pCell;
ushort dwHash2 = cell.dwHash;
```

## Извлечение примитивных данных

#### Array syntax

```
Cell* pCells;
ushort dwHash1 = (*(pCells + nCell)).dwHash;
```

```
ushort dwHash2 = pCells[nCell].dwHash;
```

## Хранение строк

- Фиксированной длины
  - Внутри родительской структуры

```
public fixed UInt16 wszValue[2];
```

- Переменной длины
  - ∞ RVA в BLOB со строками

```
public UInt16 rvaName;
```

В простом случае — поток ASCIIZ строк в UTF-16LE

```
new string((char*)(pbStrings + pCell->rvaName))
```

∞ Можно добавить header для валидации, длины, хеш-кода,...

## Извлечение строк

- ➣ Нужен ли нам string object?
  - new string() это нагрузка на GC
  - ✓ Interning, кеширование?
  - Достаточно hash code, equals, compare?
    - Можно реализовать прямо на char\*

## Извлечение строк

- ∞ new string(char\*)
  - Правильная кодировка
  - Zero-terminated
    - ✓ Или new string(char\*, int, int)

## Частные хитрости со строками

- ∞ Чтобы меньше создавать string
- Потребовать уникальность хеша
  - Выбрать хороший длинный хеш
  - Работать прямо с хешами, пока нам достаточно идентификации/сравнения
- ∞ Использовать metadata token вместо type full name

## Поиск в hash table

```
fixed(uint* pdwTable = XmlHtmlNamedCharacterReferencesOriginalDictionary.HashByValue)
 var pHeader = (Header*)pdwTable;
 byte* pCells = ((byte*)pdwTable) + sizeof(Header);
 uint hash = ch;
  if(hash == 0)
   hash = 1;
 uint nBaseRecord = hash % pHeader->NumCells;
 for(uint nProbe = 0; nProbe < pHeader->NumCells; nProbe++)
    uint nProbeRecord = (nBaseRecord + nProbe * ProbeFactor) % pHeader->NumCells;
    var pCell = (Cell*)(pCells + nProbeRecord * sizeof(Cell));
    if(pCell->dwHash == 0)
      return null; // Found a free cell
    if(pCell->wszValue[0] == ch)
     fixed(uint* pdwStrings = XmlHtmlNamedCharacterReferencesOriginalDictionary.Strings)
        return new string((char*)(((byte*)pdwStrings) + pCell->rvaName));
return null;
```

## Загрузка данных с диска

- Последовательное чтение
  - Максимально быстрое чтение
  - Занимает память
- Отображение файла в память

# Memory-Mapped Files

- 1) Отображение файла на память процесса
  - Весь файл сразу доступен как native memory
  - Лениво читается с диска
  - Не увеличивает committed memory
  - При нехватке памяти использует свой файл вместо свопа
- ~ 2) Расширение памяти процесса за счёт переключения страниц

## Memory-Mapped Files

- 2) Расширение памяти процесса за счёт переключения страниц
  - В память процесса по очереди отображаются разные небольшие участки ММF
    - Bank switching
  - Либо файл на диске, либо system swap
  - ∞ В 64-bit OS памяти много, а у 32-bit процесса мало

    - ∞ Но система может начать агрессивно свопить эту память

# Memory-Mapped Files

Memory-mapped files

+

Native memory data structure

=

Zero-load time data structure

#### Пример структуры данных

- Выжимка из метаданных
- В готовом виде для создания component container
  - Быстрая фильтрация
    - □ О атрибутам
    - □ Модуль-зонам
- Удобный API
  - В терминах Assembly / Type / Member / Attribute
- ∞ Быстрая загрузка
- ∞ Без нагрузки на GC при обходе структуры

#### Формат данных

- ∞ POD-таблицы
  - Массив повторяющихся структур с примитивными данными
    - Строки в виде RVA, поэтому тоже примитивные данные

```
Struct* _pTable;
int value = _pTable[25].IntValue;
```

### Формат данных

- Нетабличные данные
  - Поток данных переменного размера
  - Произвольные объекты
  - Строки переменной длины
  - ∞ Хеш-таблицы

# Table Record Example

```
[StructLayout(LayoutKind.Sequential, Pack = 2)]
public struct MemberRecord
  public StringRef LocalName;
  public TypeRef DeclaringType;
  public AttributeRangeRef Attributes;
  public TypeRef ValueType;
  public TypeListRangeRef ParameterTypes;
  public PartCatalogTypeMemberKind Kind;
```

# Table Record Example

```
[StructLayout(LayoutKind.Sequential, Pack = 2)]
public struct TypeRef
{
   public UInt16 Index;
}

[StructLayout(LayoutKind.Sequential, Pack = 2)]
public struct StringRef
{
   public uint Rva;
```

# Table Record Example

```
[StructLayout(LayoutKind.Sequential, Pack = 2)]
public struct TypeListRangeRef
  public ARangeRef Range;
[StructLayout(LayoutKind.Sequential, Pack = 2)]
public struct ARangeRef : IEquatable<ARangeRef>, IComparable<ARangeRef>
  public UInt16 FirstIndex;
  public UInt16 Count;
```

# Table Example

4	А	В	С	D		Ε	F	G
1	Index	LocalName [StringRef]	DeclaringType [TypeRef]	Attributes [Attr	ValueType	e [TypeRef]	ParameterTypes	[TyKind [PartCatalog
2	NULL	[NULL]	NULL	NULL	NULL		NULL	ø
3	0001h	[00001E44h] .ctor	[0001h] FooImpl - JetBrains.Platfor	NULL	[001Eh] \	Void - System.Void	NULL	Constructor
4	0002h	[00001E44h] .ctor	[0002h] TestComponent1 - JetBrains.	NULL	[001Eh] \	Void — System.Void	NULL	Constructor
5	0003h	[00001E44h] .ctor	[0004h] TestComponent2Impl - JetBra	NULL	[001Eh] \	Void — System.Void	NULL	Constructor
6	0004h	[0000211Ch] DoJob	[0005h] TestComponentWithMembers -	0009h ∑1	[001Eh] \	Void — System.Void	NULL	Method
7	0005h	[00001E44h] .ctor	[0005h] TestComponentWithMembers -	NULL	[001Eh] \	Void — System.Void	NULL	Constructor
8	0006h	[00001E44h] .ctor	[0006h] SampleAttributedComponent -	NULL	[001Eh] \	Void — System.Void	NULL	Constructor
9	0007h	[00001E44h] .ctor	[0007h] TestComponentHideRoot - Jet	NULL	[001Eh] \	Void — System.Void	NULL	Constructor
10	0008h	[00001E44h] .ctor	[0008h] TestComponentHidden - JetBr	NULL	[001Eh] \	Void — System.Void	NULL	Constructor
11	0009h	[00001E44h] .ctor	[0009h] TestComponentHiding — JetBr	NULL	[001Eh] \	Void - System.Void	NULL	Constructor
12	000Ah	[00001E44h] .ctor	[000Ah] TestComponentWithMultipleGe	NULL	[001Eh] \	Void — System.Void	NULL	Constructor
13	000Bh	[00001E44h] .ctor	[000Bh] ZoneMarker - JetBrains.Plat	NULL	[001Eh] \	Void - System.Void	NULL	Constructor
14	000Ch	[00001E44h] .ctor	[000Ch] TestComponentA - JetBrains.	NULL	[001Eh] \	Void — System.Void	0033h ∑1	Constructor
15	000Dh	[00001E44h] .ctor	[000Dh] TestComponentB - JetBrains.	NULL	[001Eh] \	Void — System.Void	0034h ∑1	Constructor
16	000Eh	[00001E44h] .ctor	[000Eh] TestComponentC - JetBrains.	NULL	[001Eh] \	√oid — System.Void	0035h ∑2	Constructor
17	000Fh	[00001E44h] .ctor	[000Fh] TestComponentD - JetBrains.	NULL	[001Eh] \	Void — System.Void	0037h ∑1	Constructor
18	0010h	[00001E44h] .ctor	[0010h] TestComponentE - JetBrains.	NULL	[001Eh] \	Void - System.Void	0037h ∑1	Constructor
19	0011h	[00001E44h] .ctor	[0011h] TestComponentF - JetBrains.	NULL	[001Eh] \	Void - System.Void	0037h ∑1	Constructor
20	0012h	[00001E44h] .ctor	[0012h] TestComponentFromMember - J	NULL	[001Eh] \	Void — System.Void	0038h ∑1	Constructor
21	0013h	[00001E44h] .ctor	[0013h] TestComponentHieroImplement	NULL	[001Eh] \	Void — System.Void	NULL	Constructor
22	0014h	[00001E44h] .ctor	[0014h] TestComponentHieroImplement	NULL	[001Eh] \	Void — System.Void	NULL	Constructor
23	0015h	[00001E44h] .ctor	[0015h] TestComponentLifetimeClient	NULL	[001Eh] \	Void — System.Void	003Ch ∑1	Constructor
24	0016h	[00001E44h] .ctor	[0016h] TestComponentMulti1 - JetBr	NULL	[001Eh] \	Void - System.Void	NULL	Constructor
25	0017h	[00001E44h] .ctor	[0017h] TestComponentMulti2 - JetBr	NULL	[001Eh] \	Void - System.Void	NULL	Constructor
26	0018h	[00001E44h] .ctor	[0018h] TestComponentMultiClient -	NULL	[001Eh] \	Void — System.Void	003Eh ∑1	Constructor
27	0019h	[00003AA0h] MethodComponent	[0019h] TestComponentWithMembers -	0014h ∑1	[003Ah] 1	IFactoriedFromMember - :	0040h ∑1	Method
28	001Ah	[00001E44h] .ctor	[0019h] TestComponentWithMembers -	NULL	[001Eh] \	Void — System.Void	003Fh ∑1	Constructor
29	001Bh	[00001E44h] .ctor	[001Ah] TestComponentPlugin - JetBr	NULL	[001Eh] \	Void — System.Void	NULL	Constructor

## Managed API

- Без native pointers
- Со всеми бизнес-классами
  - ∞ member. Туре должен вернуть объект Туре
  - member.Attributes должен вернуть коллекцию
- >> Без memory traffic при простом обходе
  - Все эти объекты не должны нагружать GC

# **Delegating Envoys**

- ∨alue type
  - Все объекты в API это структуры
  - Коллекции тоже структуры
  - ∞ C# позволяет foreach по структурам
    - ∞ Без боксинга в IEnumerable

# Delegating Envoys

- Field #1: storage object
  - Один на всю структуру данных
  - Держит native память с BLOB'ами
  - Умеет извлекать из них данные
- ➣ Field #2: Token
  - □ Примитивного типа
  - → Например, индекс записи в таблице таких объектов

# **Delegating Envoys**

- Methods & Properties
  - Все полагающиеся по API методы и проперти
  - Делегируют вызов в такую же функцию из storage object
  - → + дополнительный параметр: Token
  - ∞ Возвращает:
    - □ Примитивные типы
    - Delegating envoys
    - String envoys

```
public struct PartCatalogTypeMember : IEquatable<PartCatalogTypeMember>
  private readonly IPartCatalogStorage myStorage;
 private readonly Int32<CatalogMemberToken> Token;
  public PartCatalogType DeclaringType
   get
      return myStorage.MemberGetDeclaringType(Token);
  public StringSource Name
   get
      return myStorage.MemberGetName(Token);
```

### String Envoy

- ∞ Можно превратить в настоящий string
  - ▼ Тогда будет нагрузка на GC
  - Нет нагрузки на GC до этого
    - ∞ Должен быть value type
- Все возможные строковые операции

  - ∞ Между собой и со string
- ∞ Можно сделать из string

#### StringSource

- ∨ Value type
- Field #1: owning storage object
- Field #2: Arbitrary managed data (Object)
- Field #3: Arbitrary blittable data (12 bytes)
- Equality, Hash Code, Substring, StartsWith, etc.
  - Может представлять runtime string, native memory, managed array

#### StringSource

```
public struct StringSource : IEquatable<StringSource>,
IComparable<StringSource>, IComparable
  private readonly IStringSourceOwner myOwner;
  public object DataRef;
  public StringSourcePodData DataPod;
  public bool IsEmpty { get { return Owner.IsEmpty(ref this); } }
  public char this[uint index]
  { get { return Owner.GetCharAt(ref this, index); } }
  public uint Length { get { return Owner.GetLength(ref this); } }
  public static bool operator ==(StringSource black, StringSource white)
  { return StringSourceComparerOrdinal.Equals(ref black, ref white); }
  public string ToRuntimeString()
  { return Owner.ToRuntimeString(ref this); }
```

### StringSource Cons

- Ограниченное время жизни
  - После освобождения native memory невалиден
  - Sce методы кидают exception
  - Можно неосторожно сохранить его в кеше
    - 🗠 Функция AsManagedString() для этого
- Медленнее стандартной строки

# Collection Envoy

- → Нет нагрузки на GC при основных операциях:

  - ∞ C# foreach
  - ∞ Count
  - ∞ Contains
- Можно превратить в
  - ∞ IEnumerable`1
  - ∞ ICollection`1

#### CollectionSource

- Для списков объектов из таблиц
- ∨ Value type
- Field #1: owning storage object
- Field #2: Arbitrary managed data (Object)
- Field #3: Arbitrary blittable data (12 bytes)
  - Moжет представлять ICollection, IEnumerable, native memory, виртуальную коллекцию, вычислимый view

#### CollectionSource

- GetEnumerator: возвращает value type enumerator
  - C# foreach в таком случае
    - Зовёт public GetEnumerator напрямую
    - ∞ Не делает boxing в IEnumerable`1
    - ✓ Использует value type enumerator напрямую
    - ∞ Не делает boxing в IEnumerator`1
- → foreach без memory traffic

#### CollectionSource cons

- Не реализует интерфейсы коллекций
  - Против случайного boxing
- Нет эффективного LINQ
  - Отдельные функции вроде First(), Single()
- Есть функции AsCollection, AsEnumerable, etc
  - Boxing

# Value-type Envoys

- Load-time performance
  - Один managed storage object
    - → На самом деле несколько, но O(1)
  - Нет обработки данных на загрузке
    - ВLOВ готов к чтению по запросу
- Runtime performance
  - ∞ Все объекты API лёгкие value types
  - Возможна работа с данными без GC-аллокаций
    - Предварительная проверка и фильтрация строк и коллекций

# Example 1

## Example 2

```
foreach(PartCatalogType part
                      in catalog.ApplyFilter(attributeFilter).AllPartTypes)
  foreach(PartCatalogAttribute attribute
                          in part.GetPartAttributes<TDefinitionAttribute>())
    PartCatalogType? appliedDef =
                     attribute.ArgumentsOptional[myAttributeArgumentName]
                    .GetTypeValueIfDefined();
    myDefinitionsToParts.Add(catalog,
                        appliedDef == null ? null : appliedDef.Value.Bind());
```

# THE END